사전감지 고장예측 프로그램
AIM(Ai For Motor)

정동균(팀장), 이민아(부팀장), 김하린, 윤준서, 이용현, 황수민

1조 | 26.03.30. | 최종 발표

Contents

01
팀 소개
프로젝트 팀 'AIM' 및 팀원 소개

02
제안 배경 및 목표
사후 유지보수의 한계 및 진동 예측 시스템 기획

03
전체 시스템 구조
프로젝트 시스템 흐름 및 데이터 파이프라인

04
기술 스택 및 WBS
AI 모델링 및 FE/BE 구현 상세 기술과 프로젝트 일정

05
데이터 전처리 및 AI 모델링
사용한 데이터셋과 핵심 지표 추출 및 통합 예측 파이프라인 구축

06
AI 성능 평가 및 결과 분석
모델 평가지표(Precision, Recall) 리포트 및 혼동 행렬(Confusion Matrix) 분석

07
주요 기능 및 UI/UX 구성
실시간 다중 설비 모니터링 및 직관적 통계 대시보드

08
기대 효과 및 향후 발전 방향
다운타임 제로화 달성 및 다중 클래스 고도화 비전

01. 팀 소개

AIM (Ai For Motor)

'목표(Aim)'라는 중의 적인 의미와 'AI for Motor'라는 의미를 가지는 팀 명으로 전문성 기술 스택 AI와 대상인 Motor가 명확히 드러납니다. 베어링 뿐만 아니라 모터 전반의 고장을 잡겠다는 포부의 의미를 가집니다.

정동균

- 프로젝트 총괄 (PM)
- 전체 시스템 구조 관리
- 데이터 수집 및 모델 학습
- 데이터 파이프라인 설계
- 모델 학습 총괄 및 시뮬레이터 개발

이민아

- 프로젝트 기획 (PO)
- 서비스 기능 정의
- 요구 사항 설계
- 학습용 데이터셋 구축
- 데이터 기반 기능 개선 및 프로젝트 조율

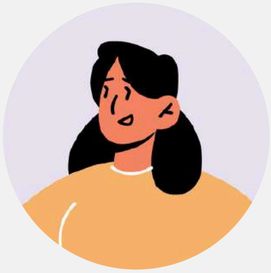

김하린

- 화면설계
- UI / UX 디자인
- 프론트엔드 화면 구현
  - 대시보드
  - 데이터로그
  - 데이터분석
- 백엔드 API 구현 (일부)

윤준서

- 진동 센서 특징 분석
- 모터별 고장 확률 예측 모델 개발
- 고장 유형 분류 모델 개발
- Warning/Fault Threshold 기반 단계형 예측 시스템 구현

이용현

- FastAPI 기반 백엔드 코어 로직 설계
- REST API 경로 정의
- DB 컬렉션 구조 설계
- 프론트엔드 API·소켓 연동 상태관리
- 시뮬레이터 개발

황수민

- 진동 센서 특징 분석
- 모터별 고장 확률 예측 모델 개발
- 고장 유형 분류 모델 개발
- Warning/Fault Threshold 기반 단계형 예측 시스템 구현

02. 제안 배경 및 목표

사후 유지보수의 한계 및 진동 예측 시스템 기획

예기치 않은 설비 다운 타임

모터의 돌발적인 고장으로 인해 공정이 중단될 경우 막대한 생산 손실과 경제적 피해가 발생합니다.

기존 유지보수방식의 비효율성

고장 후 수리하는 사후 정비나 정해진 주기마다 교체하는 예방 정비는 불필요한 유지보수 비용 낭비를 초래합니다.

베어링 이상 조기 감지 시급

모터 고장의 주원인인 베어링의 진동 데이터를 분석하여 이상 징후를 사전에 예측하고 대비해야 합니다.

기획 목표 : 1초당 4,000건의 복잡한 진동 데이터를 실시간 수집 및 분석하여 고장 발생 전 사전 고장 확률을 정밀하게 계산하고 직관적으로 시각화 하는 모니터링 시스템 구축

02. 제안 배경 및 목표

사후 유지보수의 한계 및 진동 예측 시스템 기획

01 진동 데이터 특화 AI 학습

다양한 센서 중 고장 판별에 가장 효과적인 진동 데이터를 선별하여 분석 효율 극대화하고 정상/비정상 데이터를 균형 있게 짝 맞춤 하여 데이터 편향을 해소하고 학습 신뢰도 확보

02 고장 유형 정밀 분류

단순 이상 감지를 넘어 고장 유형을 세분화하여 예측하는 분류 모델 구현하고 초기 파형이 유사해 혼동하기 쉬운 클래스 간의 원인을 분석하고 재현율 중심의 평가지표 확립

03 직관적인 UI/UX 시각화

육안으로 파악하기 힘든 원시 파형 그래프 노출을 지양하고 프론트엔드 화면을 사용자 친화적으로 간소화하며 이상 진동이 발생한 핵심 구간을 확대해 위험도에 따른 직관적인 알림 적용

04 실시간 통합 모니터링

전체 설비의 종합적인 상태와 과거 이력을 한눈에 파악할 수 있는 메인 대시 보드를 구축하고 분할된 카드뷰 인터페이스를 통해 여러 장비의 상태를 지연 없이 실시간으로 동시 관제

05 데이터 선순환 및 재학습

기존의 수기 데이터(CSV 파일) 업로드 시 즉각적으로 고장 여부를 판별하는 기능 제공하고 사용자 피드백을 통해 확정된 고장 이력을 저장하고 이를 추후 AI 모델 업데이트에 활용할 수 있는 기반 구축

02. 제안 배경 및 목표(요구 사항)

사후 유지보수의 한계 및 진동 예측 시스템 기획 목표

01. 대분류	02. 중분류	03. 항목 / 기능	04. 상세 내용	05. 비고 (기술 / 조건)
1. 프로젝트 개요	1.1 프로젝트명	시스템 명칭	AI 기반 모터 베어링 사전 고장 예측 시스템	
	1.2 프로젝트 목적	개발 목적	센서 데이터 분석으로 베어링 이상 조기 감지, 고장 예측을 통한 유지보수 효율 향상	
	1.3 시스템 목표	핵심 목표	고장 예측, 실시간 모니터링, 데이터 시각화, 사전 알림	
2. 시스템 구성	2.1 아키텍처	전체 데이터 흐름	프론트엔드 → API 서버 → 머신러닝 → DB	
	2.2 사용 기술	프론트엔드	사용자 대시보드 및 UI 구현	React
		백엔드	API 서버 구축 및 데이터 연동	FastAPI
		머신러닝	고장 예측 모델 학습 및 추론	scikit-learn, TensorFlow
		데이터베이스	센서 로그 및 예측 결과 저장	MongoDB
3. 기능 요구사항	3.1 센서 데이터 관리	데이터 입력 및 수집	진동, 온도, 전류, 측정 시간 데이터 수집 및 검증	1초 2000개 고주파 데이터 처리 방식 고려 필요
	3.2 데이터 저장	DB 저장 기능	입력된 데이터를 DB에 기록 (학습 및 과거 분석용)	
	3.3 고장 예측	머신러닝 예측	데이터 기반 베어링 고장 여부(정상/고장) 및 확률(%) 계산	RandomForest, XGBoost, LSTM
	3.4 이상 상태 알림	사전 경고 알림	예측된 고장 확률이 80% 이상일 경우 화면에 경고 표시	예: ⚠ 베어링 이상 가능성 높음
	3.5 데이터 시각화	센서 그래프 렌더링	진동의 변화 추이를 차트로 제공	
	3.6 예측 기록 조회	과거 이력 확인	시간별 데이터, 고장 발생 이력, 과거 센서 기록 조회 기능	

02. 제안 배경 및 목표(요구 사항)

사후 유지보수의 한계 및 진동 예측 시스템 기획 목표

01. 대분류	02. 중분류	03. 항목 / 기능	04. 상세 내용	05. 비고 (기술 / 조건)
4. 비기능 요구사항	4.1 성능 요구사항	응답 및 처리 속도	데이터 처리 시간 1초 이내, API 응답 시간 2초 이하	
	4.2 보안 요구사항	시스템 보안	API 접근 제한 및 데이터 무결성 유지	
	4.3 사용성 요구사항	UI/UX	직관적인 대시보드, 그래프 중심 표현, 실시간 렌더링	
5. API 요구사항	5.1 데이터 저장 API	POST /sensor	JSON 입력: vibration, temperature, current	
	5.2 고장 예측 API	POST /predict	JSON 출력: prediction(상태), probability(확률)	
	5.3 데이터 조회 API	GET /sensor-data	저장된 센서 데이터 리스트 조회	
		GET /prediction-history	과거 예측 이력 리스트 조회	
6. 데이터 구조	6.1 Sensor Data	sensor_data 컬렉션	timestamp, vibration, temperature, current	
	6.2 Prediction	prediction_results 컬렉션	timestamp, prediction(결과), probability(확률)	
7. 사용자 인터페이스	대시보드 화면	메인 모니터링 뷰	현재 센서 수치, 예측 결과 및 확률 표시, 알림 컴포넌트	
	그래프 화면	시각화 뷰	시간 흐름에 따른 진동/온도/전류 변화 라인 차트	
8. 개발 환경	인프라 및 언어	운영체제 / 개발 언어	Windows 또는 Linux / Python, JavaScript	

03. 전체 시스템 구조

프로젝트 시스템 흐름 및 데이터 파이프라인

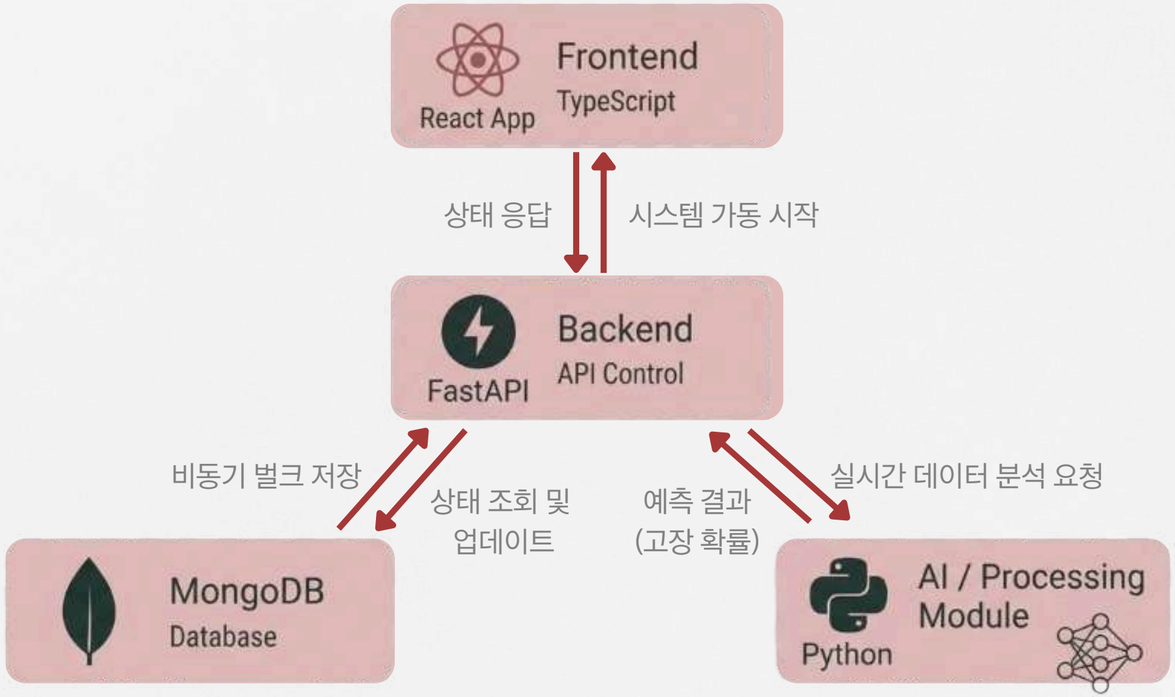

구조 특징 : 프론트엔드와 백엔드 간 지연 없는 API 연동으로 다중 설비에서 쏟아지는 센서 데이터를 분석하고 고장 확률을 실시간으로 대시보드에 렌더링하는 파이프라인 완성

04. 기술 스택 및 WBS

AI 모델링 및 FE/BE 구현 상세 기술과 프로젝트 일정

Frontend

JavaScript

React

Axios

Backend / DB

FastAPI

Python

MongoDB

AI / ML

Scikit-learn

TensorFlow

RandomForest / XGBoost / LSTM

Tools & Infra

Windows

Git / Notion

VS Code / Figma

04. 기술 스택 및 WBS

AI 모델링 및 FE/BE 구현 상세 기술과 프로젝트 일정

진행여부	목표일정	D-DAY	구분	상세	진척도	담당자					
						균	민	린	서	현	수
완료	03.12-18		**1. 기획 및 설계**	프로젝트 주제 및 목표 설정	100%						
완료				요구사항 정의서 작성	100%						
완료				화면 와이어프레임 설계	100%						
완료				기획 발표 자료(PPT) 제작	100%						
완료		3.18		기획 발표	100%						
완료	03.18-03.21		**2. 디자인 및 아키텍처**	UI/UX 화면 디자인	100%						
완료				데이터베이스(ERD) 설계	100%						
완료				API 명세서 작성	100%						
완료		3.21		개발 환경 세팅 및 깃허브 구축	100%						
완료	03.21-03.25		**3. 본격 개발 및 멘토링**	프론트엔드 UI 퍼블리싱	100%						
완료				백엔드 주요 기능 및 서버 개발	100%						
완료				중간 멘토링	100%						
완료				멘토링 피드백 반영 및 수정	100%						
완료	03.25-03.28		**4. 시스템 연동 및 고도화**	프론트-백엔드 API 연동	100%						
완료				세부 추가 기능 구현	100%						
완료				전반적인 코드 최적화	100%						
완료				버그 수정 (디버깅)	100%						
완료	03.28-03.30		**5. 테스트 및 마감**	시스템 통합 테스트 및 QA	100%						
완료				최종 발표 자료(PPT) 제작	100%						
완료		03.30		최종 발표	100%						

05. 데이터 전처리 및 AI 모델링(사용한 데이터셋)

사용한 데이터셋과 핵심 지표 추출 및 통합 예측 파이프라인 구축

구 분		최종데이터(진동/전류)	
정상데이터		1,098,327	
고장데이터	베어링 불량	367,929	1,234,845
	회전체 불평형	223,502	
	축정렬 불량	330,651	
	벨트 느슨함	312,763	
합계		2,333,172	

기계시설물 고장 예지 센서

https://aihub.or.kr/aihubdata/data/view.do?pageIndex=2&currMenu=115&topMenu=100&srchOptnCnd=OPTNCND001&searchKeyword=%EC%84%A4%EB%B9%84&srchDetailCnd=DETAILCND001&srchOrder=ORDER001&srchPagePer=20&aihubDataSe=data&dataSetSn=238

05. 데이터 전처리 및 AI 모델링

사용한 데이터셋과 핵심 지표 추출 및 통합 예측 파이프라인 구축

```
# RMS (Root Mean Square)
rms = float(np.sqrt(np.mean(signal ** 2)))
# STD (Standard Deviation, 표준편차)
std = float(np.std(signal))
# Peak-to-Peak
peak2peak = float(np.max(signal) - np.min(signal))
# Kurtosis (첨도)
kurtosis = float(stats.kurtosis(signal))  # scipy: excess kurtosis (정규=0)
# Crest Factor (파고율)
crest = float(np.max(np.abs(signal)) / (rms + 1e-9))
# Skewness (왜도)
skewness = float(stats.skew(signal))
return dict(
    rms=rms, std=std, peak2peak=peak2peak,
    kurtosis=kurtosis, crest_factor=crest, skewness=skewness
)
```

1 특징(Feature) 추출 알고리즘

복잡한 원시 진동 파형을 그대로 사용하는 대신 진동의 물리적 특성을 반영하는 통계 기반 특징을 추출하여 모델 학습 효율과 해석 가능성을 동시에 확보했습니다.

- RMS, STD → 진동 크기 및 불안정성
- Kurtosis → 충격성 결함 감지
- Peak-to-Peak
- Crest Factor, Skewness → 비정상 패턴 분석

05. 데이터 전처리 및 AI 모델링

사용한 데이터셋과 핵심 지표 추출 및 통합 예측 파이프라인 구축

```
# RMS (Root Mean S
rms = float(np.sqr
# STD (Standard De
std = float(np.std
# Peak-to-Peak
peak2peak = float(
# Kurtosis (첨도)
kurtosis = float(s
# Crest Factor (피
crest = float(np.m
# Skewness (왜도)
skewness = float(s
return dict(
    rms=rms, std=s
    kurtosis=kurto
)
```

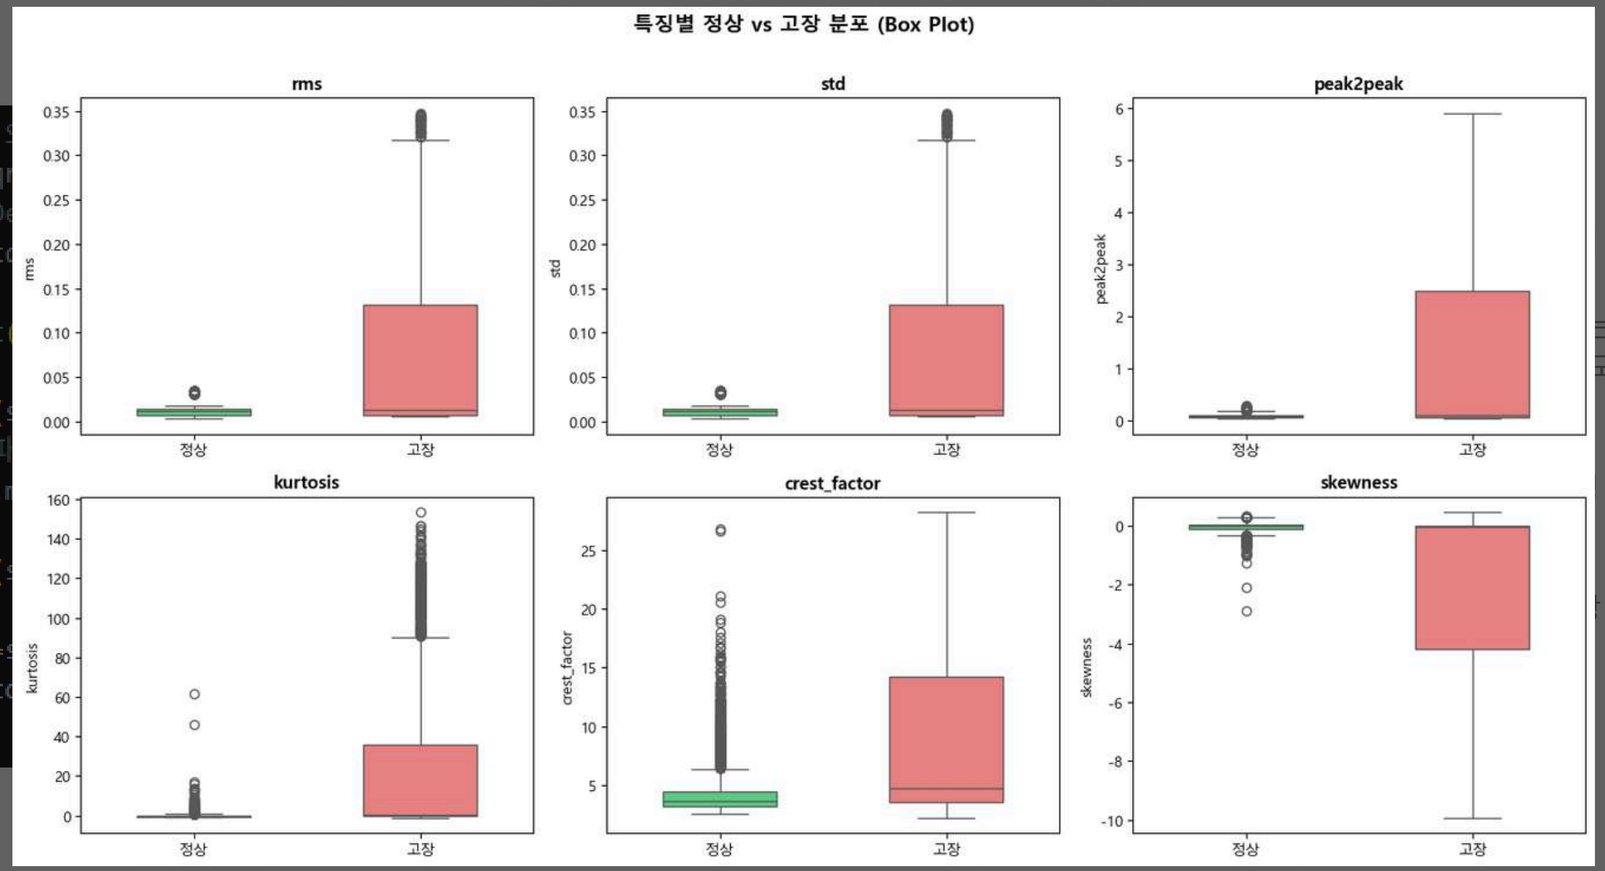

는 대신 진동의 물리적 특성
모델 학습 효율과 해석 가능

패턴 분석

05. 데이터 전처리 및 AI 모델링

사용한 데이터셋과 핵심 지표 추출 및 통합 예측 파이프라인 구축

```python
for csv_path in csv_files:
        parts       = csv_path.parts
        fault_type  = parts[-2]
        motor_model = parts[-3]
        power_kw    = float(parts[-4].replace("kW", ""))
        motor_model = parts[-3]
        fault_type = parts[-2]

        signal = pd.read_csv(csv_path, skiprows=SKIP_ROWS, header=None).values.flatten()[:SIGNAL_LEN]
        feat = extract_features(signal)

        feat["power_kw"] = power_kw
        feat["motor_model"] = motor_model
        feat["fault_type"] = fault_type
        feat["label"] = 0 if fault_type == "정상" else 1

        records.append(feat)
```

1 6,992개 샘플 가공 및 라벨링

CSV 파일을 순회하며 각 데이터에서 진동 신호를 읽고 통계 기반 Feature를 추출한 뒤 모터 정보(kW)와 고장 유형을 함께 결합하여 정상(0), 고장(1)으로 라벨링된 학습 데이터셋을 구성했습니다.

05. 데이터 전처리 및 AI 모델링

사용한 데이터셋과 핵심 지표 추출 및 통합 예측 파이프라인 구축

```
for csv_pat
        par
        fau
        mot
        pow
        mot
        fau

        sig
        fea

        fea
        fea
        fea
        fea

        rec
```

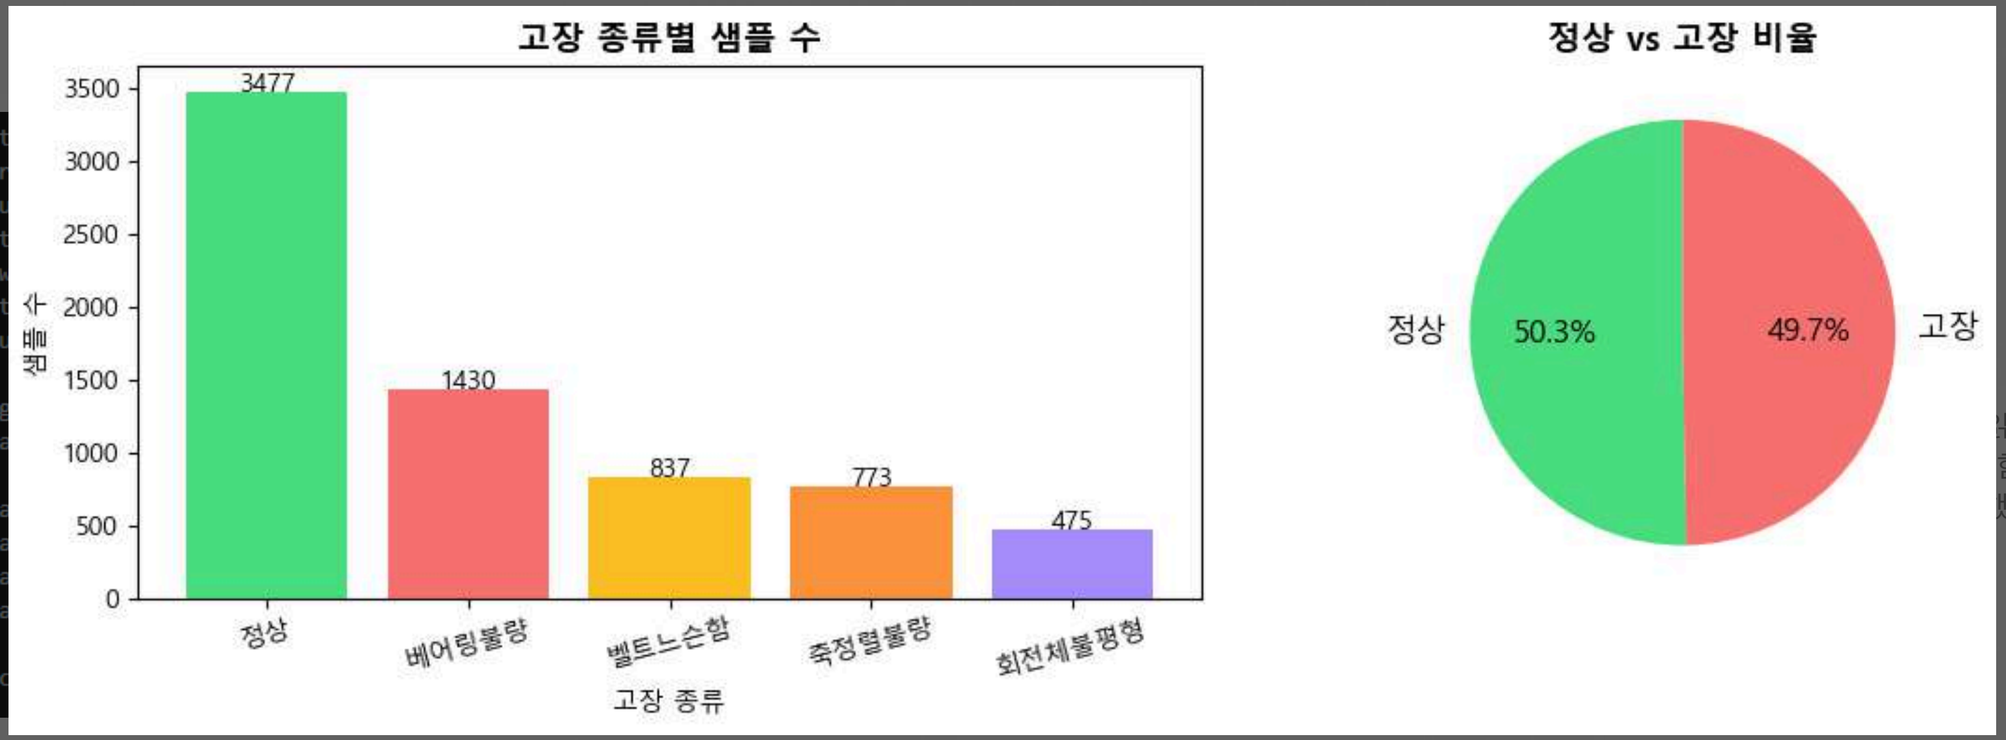

고 통계 기반
함께 결합하여
습니다.

05. 데이터 전처리 및 AI 모델링

사용한 데이터셋과 핵심 지표 추출 및 통합 예측 파이프라인 구축

```python
# ── Pipeline 정의 ──────────────────────────────────────────
# Pipeline = 전처리 + 모델을 하나로 묶어서 관리
# → 예측 시에도 동일한 scaler가 자동 적용됨
pipeline = Pipeline([
    # Step 1: StandardScaler — 각 특징을 평균 0, 표준편차 1로 정규화
    ("scaler", StandardScaler()),

    # Step 2: RandomForest 분류기
    ("model", RandomForestClassifier(
        n_estimators=300,       # 나무 300그루 — 많을수록 안정적이지만 느려짐
        max_depth=None,         # 깊이 제한 없음 (데이터가 충분하므로)
        class_weight="balanced",# 정상 많고 고장 적어도 자동 보정
        random_state=42,        # 재현성 보장
        n_jobs=-1,              # CPU 코어 전부 사용해서 병렬 학습
    ))
])

print("✅ 파이프라인 정의 완료")
print(pipeline)
```

1 8:2 최적 분할 및 밸런스 유지

구축된 6,992개의 데이터를 학습셋 5,593개(80%)와 테스트셋 1,399개(20%)로 분할했습니다. 이때 정상/고장 클래스 비율이 양쪽 모두 5:5로 유지되도록 설정하여 학습 편향을 원천 차단했습니다.

2 단일 통합 파이프라인(Pipeline) 구축

StandardScaler를 통해 Feature 간 스케일 차이를 제거하고 이를 RandomForest 모델과 하나의 Pipeline으로 구성하여 전처리와 예측이 일관되게 수행되도록 설계했습니다.

05. 데이터 전처리 및 AI 모델링

사용한 데이터셋과 핵심 지표 추출 및 통합 예측 파이프라인 구축

```
# ── Pipeline 정
# Pipeline = 전
# → 예측 시에도 동
pipeline = Pipe
    # Step 1: S
    ("scaler",

    # Step 2: R
    ("model", R
        n_estim
        max_dep
        class_w
        random_
        n_jobs=
    ))
])

print("✅ 파이프
print(pipeline)
```

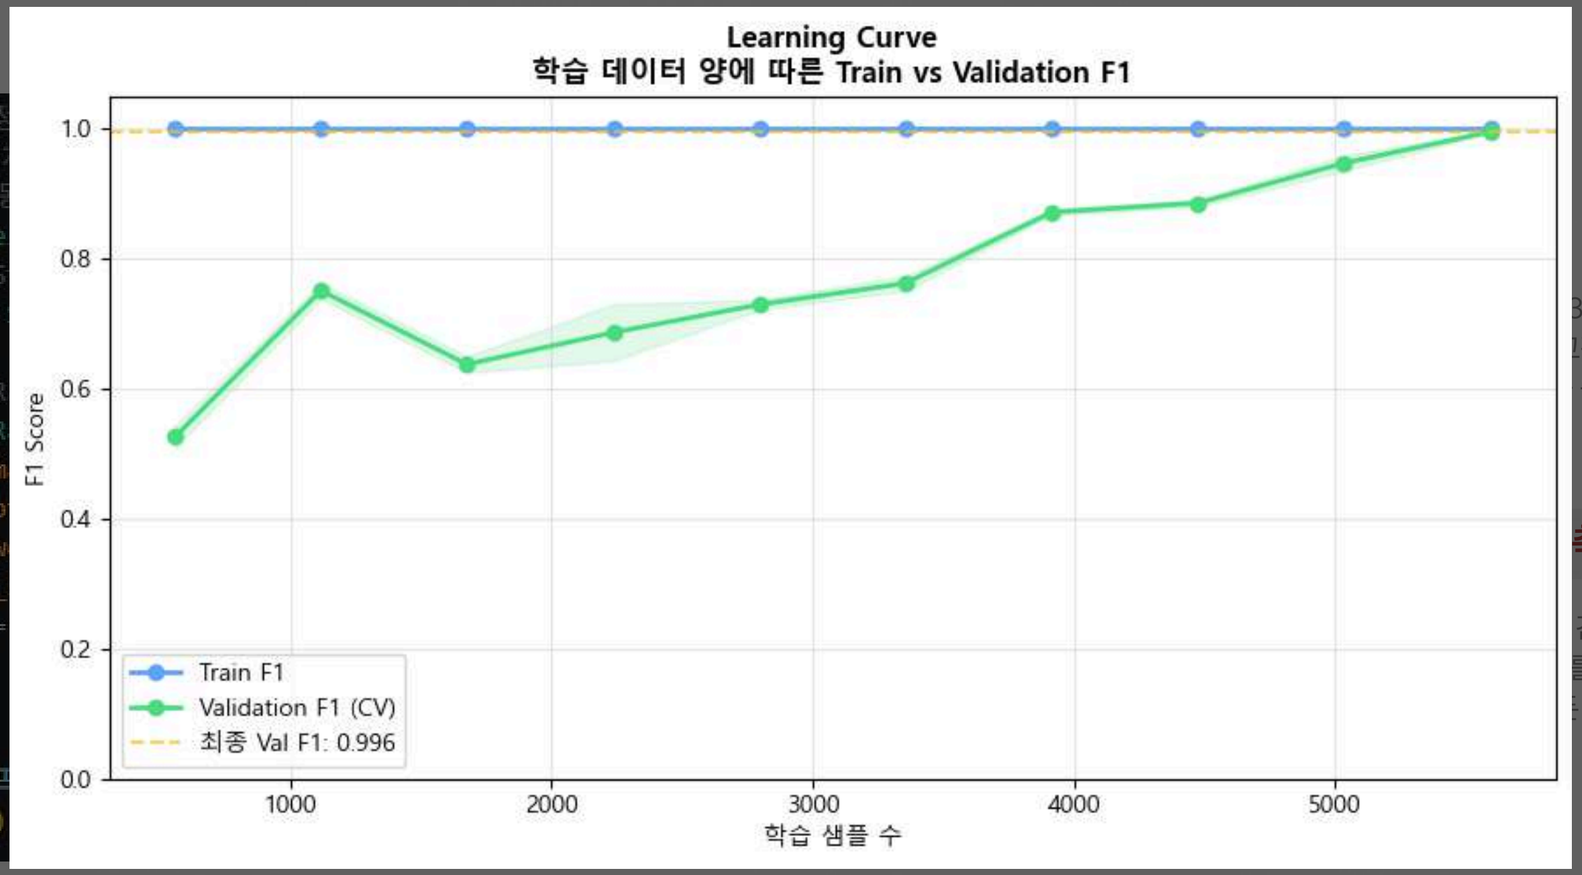

3개(80%)와 테스트셋
장 클래스 비율이 양쪽
원천 차단했습니다.

축

간의 스케일 격차를
를 RandomForest
모터 용량을 커버하는

06. AI 성능 평가 및 결과 분석

모델 평가지표(Precision, Recall) 리포트 및 혼동 행렬(Confusion Matrix) 분석

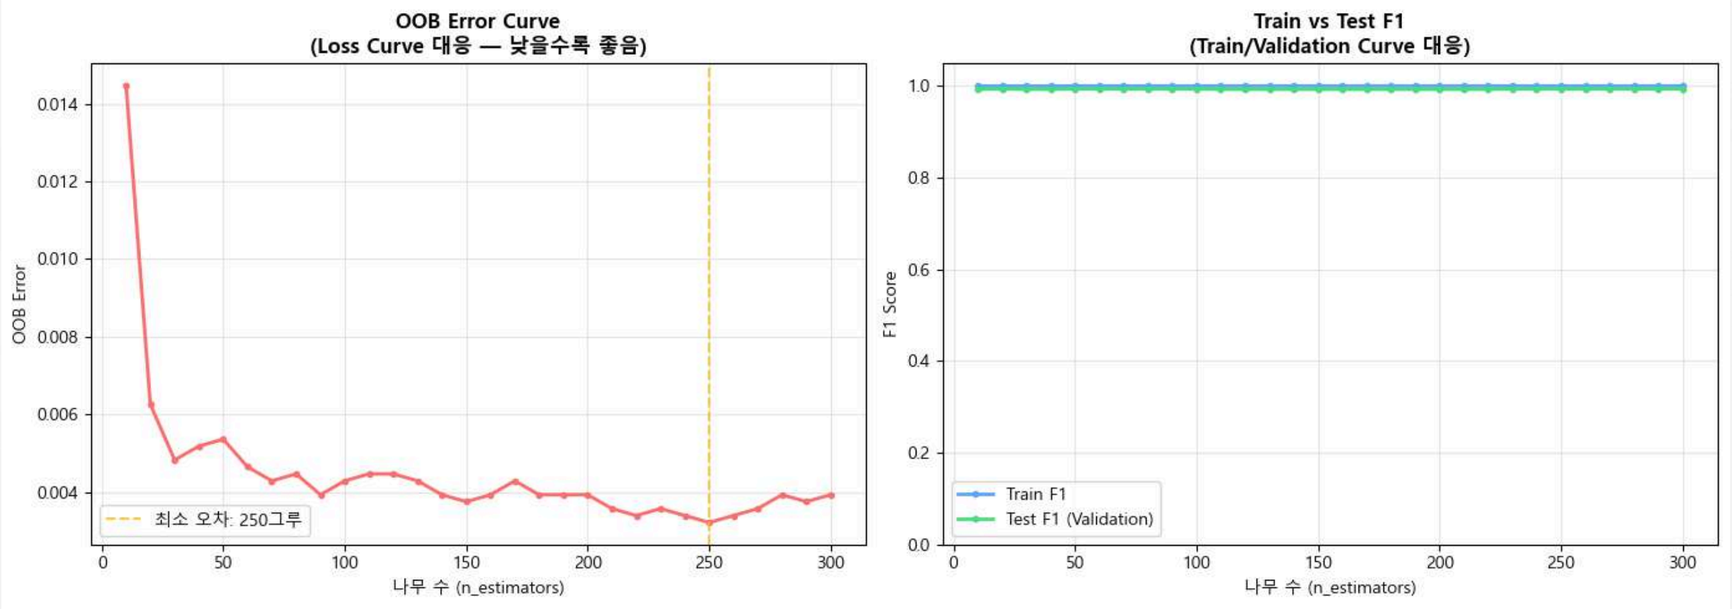

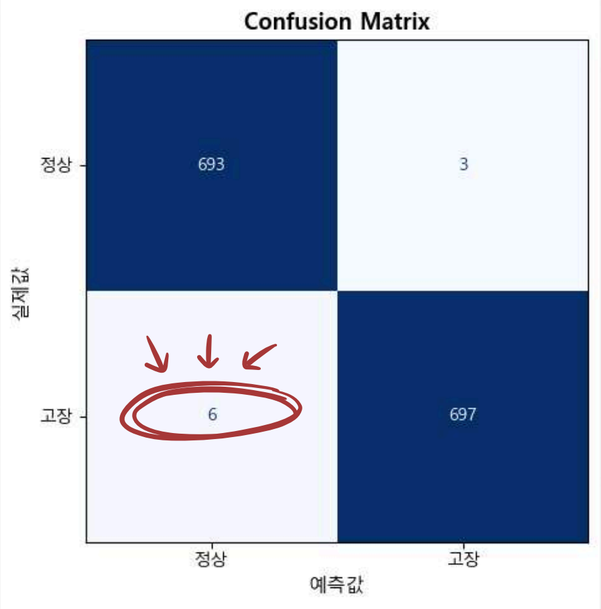

1 높은 수준의 예측 성능

학습 과정에서 Train과 Validation F1 Score가 모두 1.0에 근접하며 안정적으로 유지되었고 데이터 증가에 따라 모델이 과적합 없이 일반화 성능을 확보했음을 확인했습니다. 또한 OOB Error가 감소 후 안정화되며 모델이 충분히 수렴했음을 확인했습니다.

2 치명적 고장 놓침 완벽 방어

1,399개의 테스트 샘플을 혼동 행렬(Confusion Matrix)로 분석한 결과 전체 예측 오류는 단 9건에 불과했습니다. 특히 실제 고장을 정상으로 판단하는 치명적인 오류는 단 6건으로 최소화하여 시스템 신뢰도를 확보했습니다.

06. AI 성능 평가 및 결과 분석

모델 평가지표(Precision, Recall) 리포트 및 혼동 행렬(Confusion Matrix) 분석

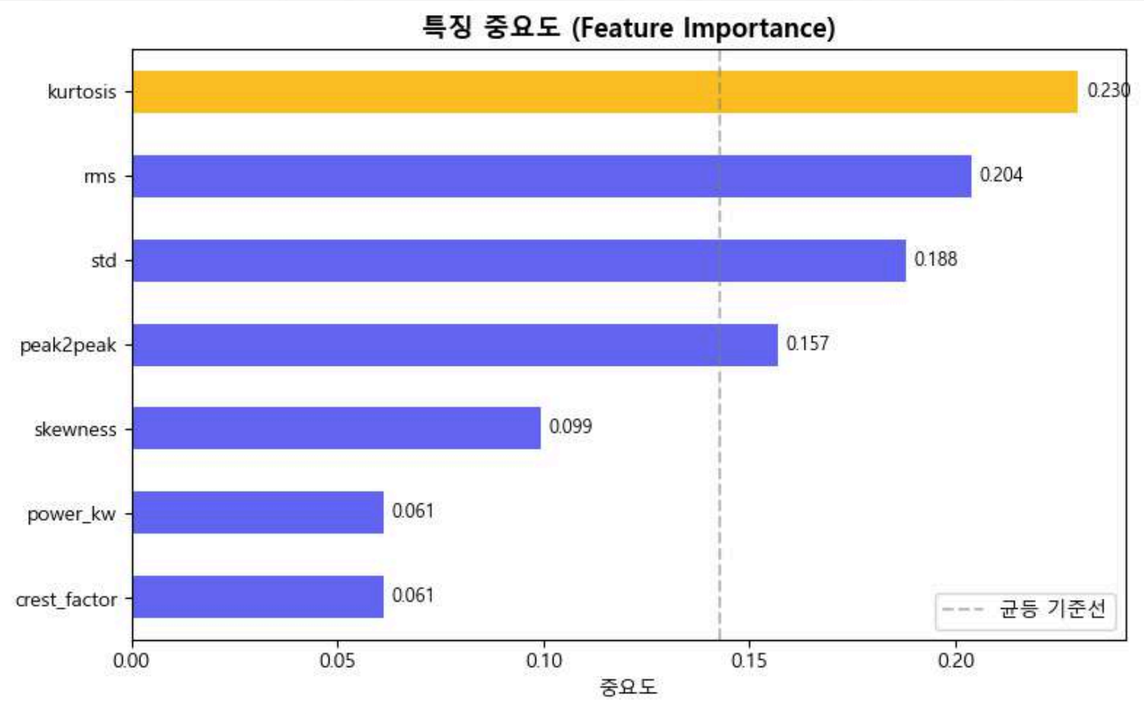

1 설명 가능한 AI (XAI) 구현

모델의 Feature Importance를 분석하여 AI가 단순한 블랙박스가 아니라 어떤 특징을 기반으로 판단하는지 해석 가능한 구조임을 확인했습니다.

2 분석 인사이트

분석 결과 단순 진동 크기(RMS)보다 베어링의 충격을 나타내는 Kurtosis와 진동 불안정성을 나타내는 STD가 고장 예측에 더 중요한 영향을 미치는 것으로 확인되었습니다.

07. 주요 기능 및 UI/UX 구성

실시간 다중 설비 모니터링 및 직관적 통계 대시보드

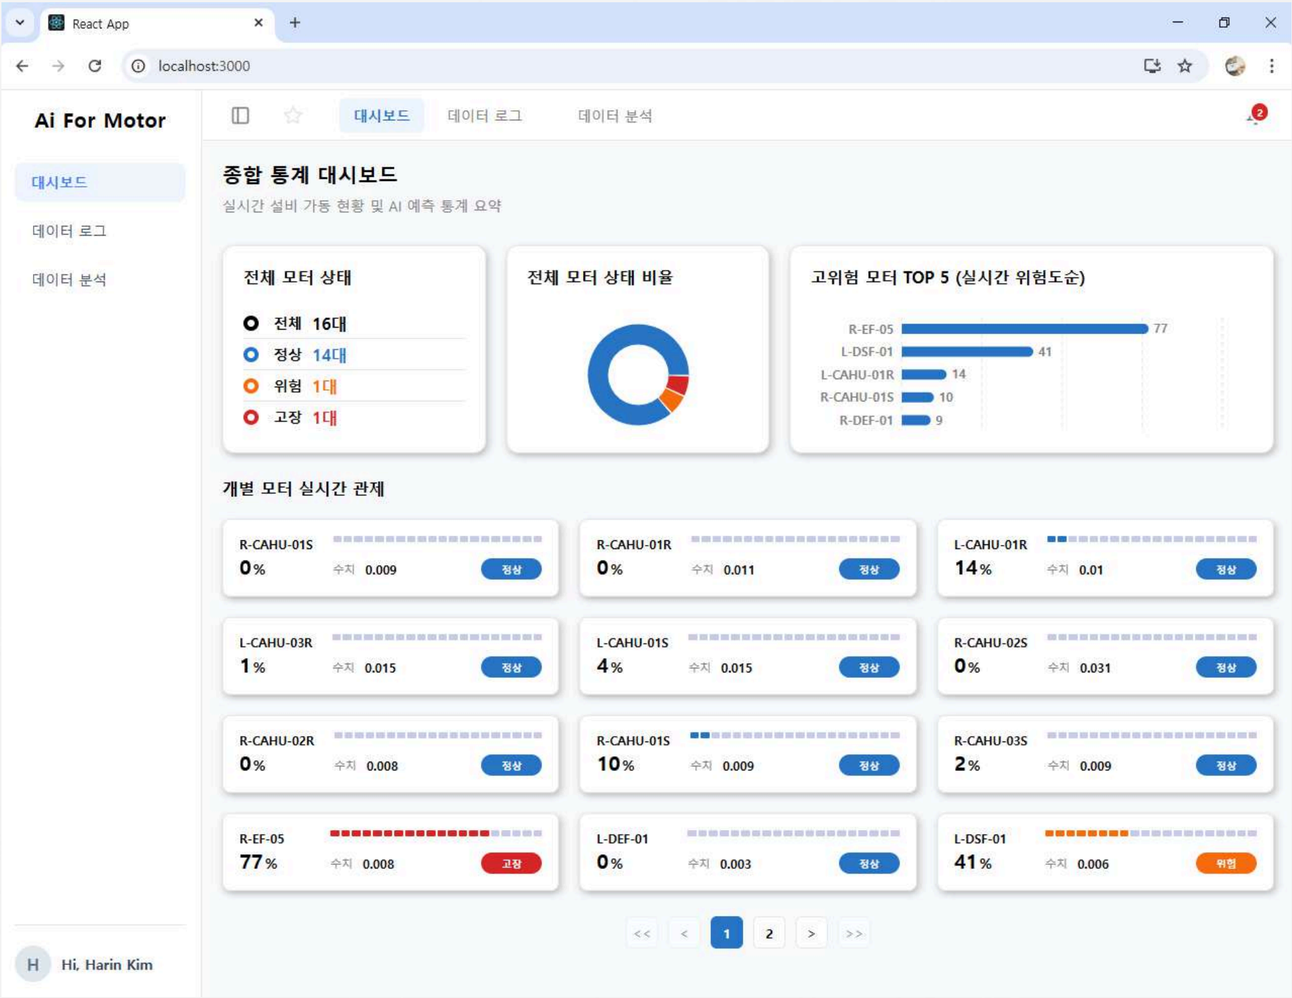

대시 보드

1. 전체 모터 상태 요약 (전체/정상/위험/고장)
2. 모터 상태 비율 시각화
3. 고위험 모터 TOP 5 (실시간 위험도순)
4. 개별 모터 실시간 관제 현황

07. 주요 기능 및 UI/UX 구성

실시간 다중 설비 모니터링 및 직관적 통계 대시보드

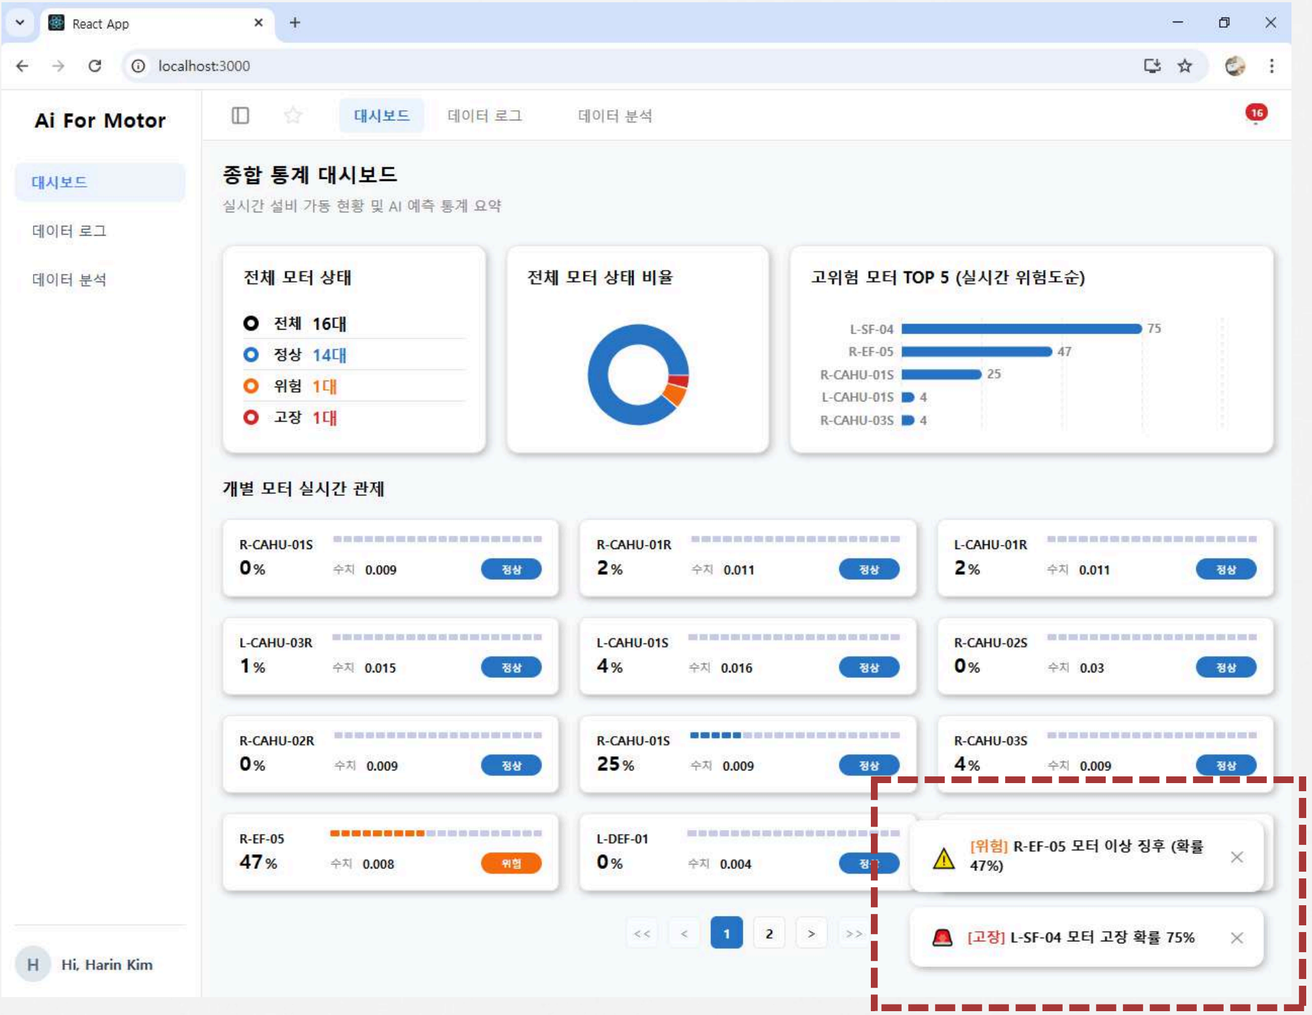

대시 보드

1. 전체 모터 상태 요약 (전체/정상/위험/고장)
2. 모터 상태 비율 시각화
3. 고위험 모터 TOP 5 (실시간 위험도순)
4. 개별 모터 실시간 관제 현황

07. 주요 기능 및 UI/UX 구성

실시간 다중 설비 모니터링 및 직관적 통계 대시보드

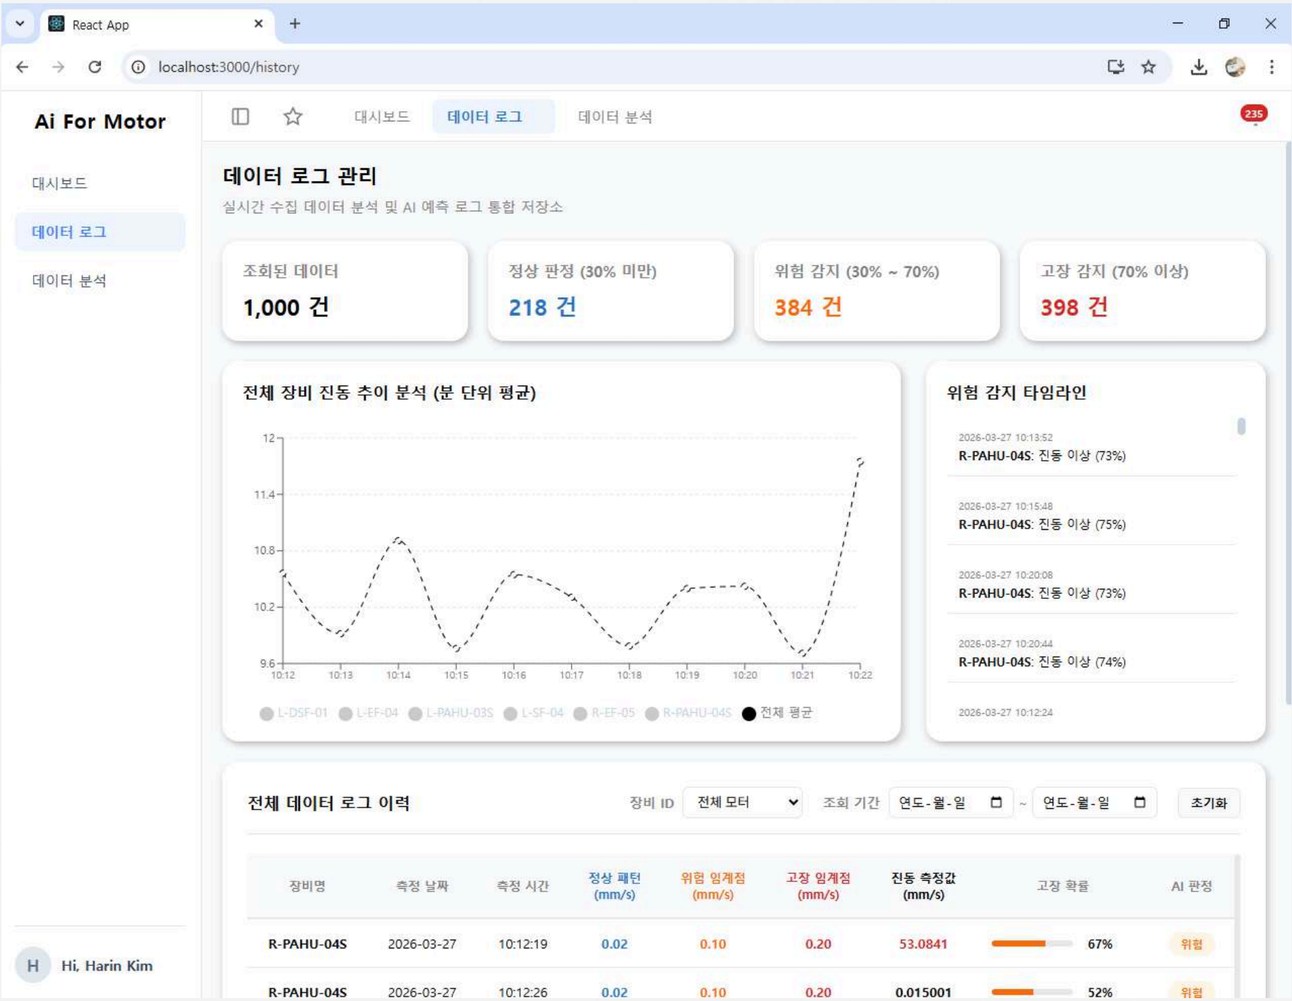

데이터 로그

1. 장비 ID 및 조회 기간별 맞춤 필터링
2. 측정 시간별 진동 및 전류 수치 상세 조회
3. 설비별 실시간 고장 확률(%) 시각화
4. AI 판정 상태(정상/주의/위험) 리스트 제공 및 페이지 이동

07. 주요 기능 및 UI/UX 구성

실시간 다중 설비 모니터링 및 직관적 통계 대시보드

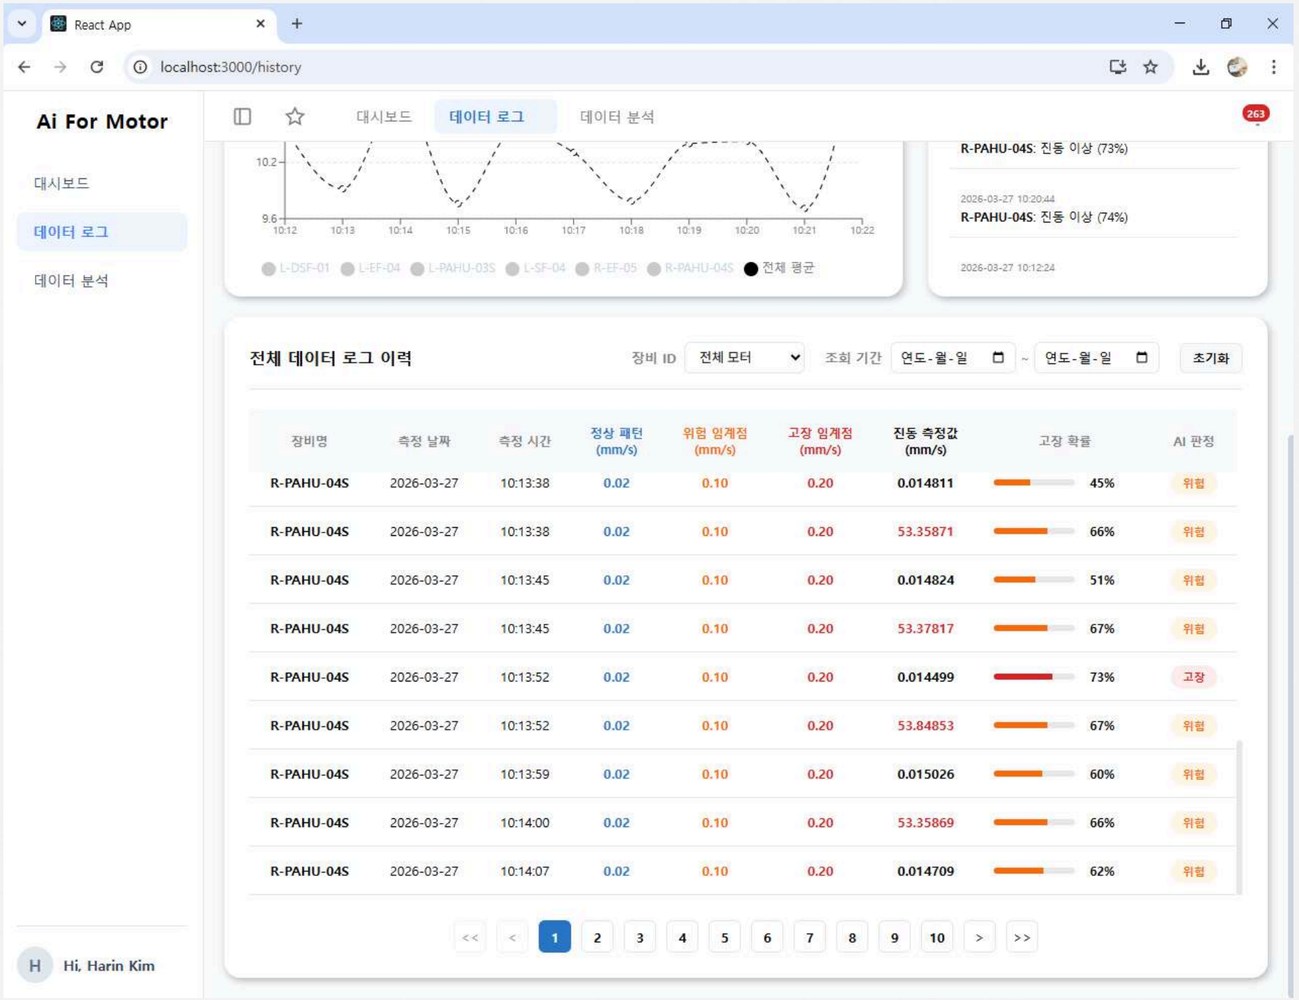

장비명	측정 날짜	측정 시간	정상 패턴 (mm/s)	위험 임계점 (mm/s)	고장 임계점 (mm/s)	진동 측정값 (mm/s)	고장 확률	AI 판정
R-PAHU-04S	2026-03-27	10:13:38	0.02	0.10	0.20	0.014811	45%	위험
R-PAHU-04S	2026-03-27	10:13:38	0.02	0.10	0.20	53.35871	66%	위험
R-PAHU-04S	2026-03-27	10:13:45	0.02	0.10	0.20	0.014824	51%	위험
R-PAHU-04S	2026-03-27	10:13:45	0.02	0.10	0.20	53.37817	67%	위험
R-PAHU-04S	2026-03-27	10:13:52	0.02	0.10	0.20	0.014499	73%	고장
R-PAHU-04S	2026-03-27	10:13:52	0.02	0.10	0.20	53.84853	67%	위험
R-PAHU-04S	2026-03-27	10:13:59	0.02	0.10	0.20	0.015026	60%	위험
R-PAHU-04S	2026-03-27	10:14:00	0.02	0.10	0.20	53.35869	66%	위험
R-PAHU-04S	2026-03-27	10:14:07	0.02	0.10	0.20	0.014709	62%	위험

데이터 로그

1. 장비 ID 및 조회 기간별 맞춤 필터링
2. 측정 시간별 진동 및 전류 수치 상세 조회
3. 설비별 실시간 고장 확률(%) 시각화
4. AI 판정 상태(정상/주의/위험) 리스트 제공 및 페이지 이동

07. 주요 기능 및 UI/UX 구성

실시간 다중 설비 모니터링 및 직관적 통계 대시보드

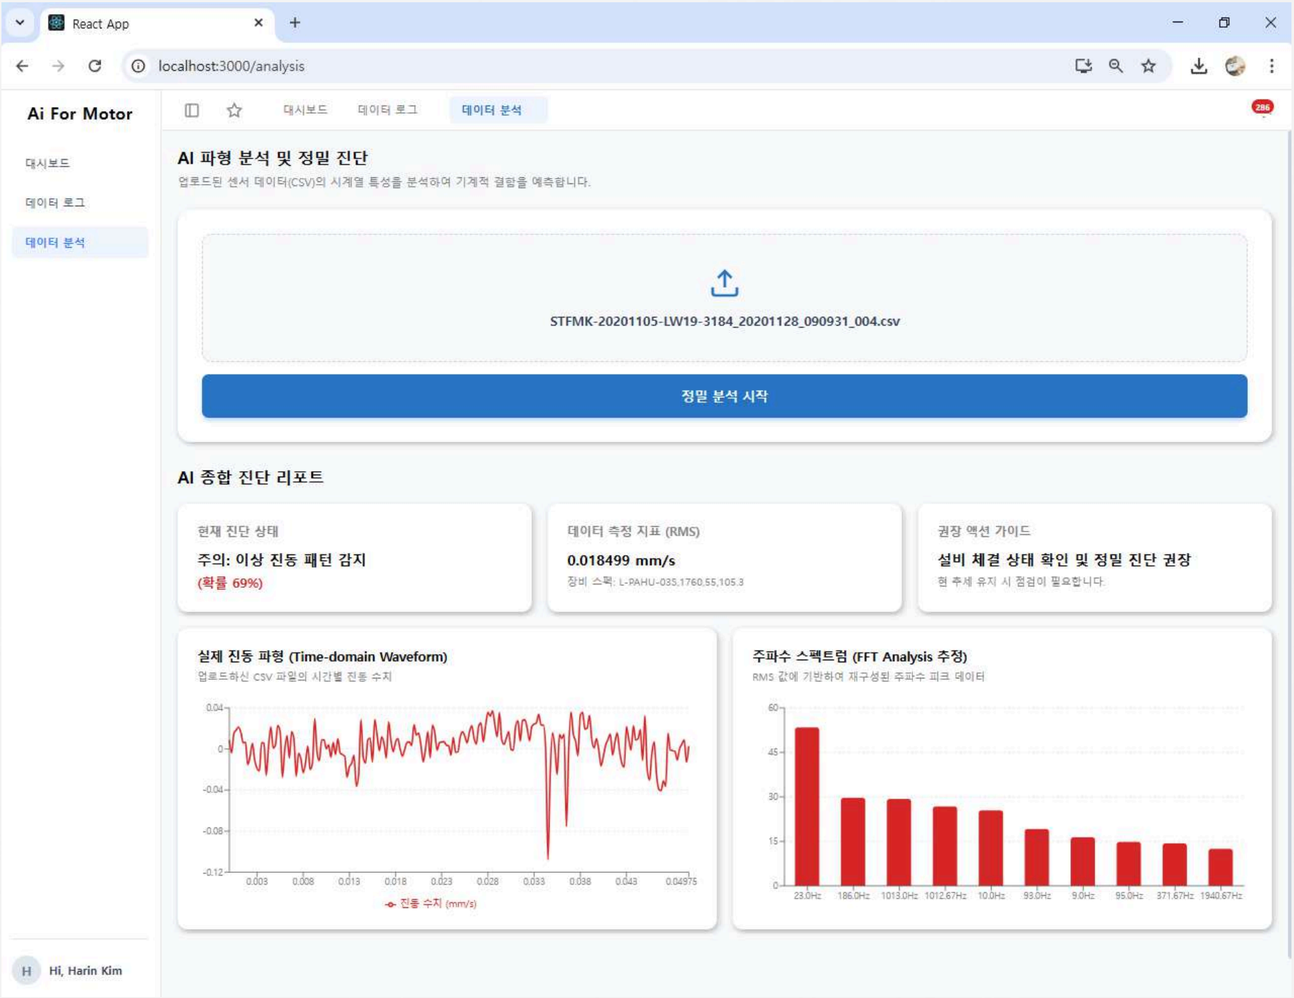

데이터 분석

1. 센서 데이터(CSV) 업로드 및 분석
2. AI 종합 진단 리포트 제공
3. 실제 진동 파형(Time-domain) 시각화
4. 주파수 스펙트럼(FFT 추정) 분석

08. 기대 효과 및 향후 발전 방향

다운타임 제로화 달성 및 다중 클래스 고도화 비전

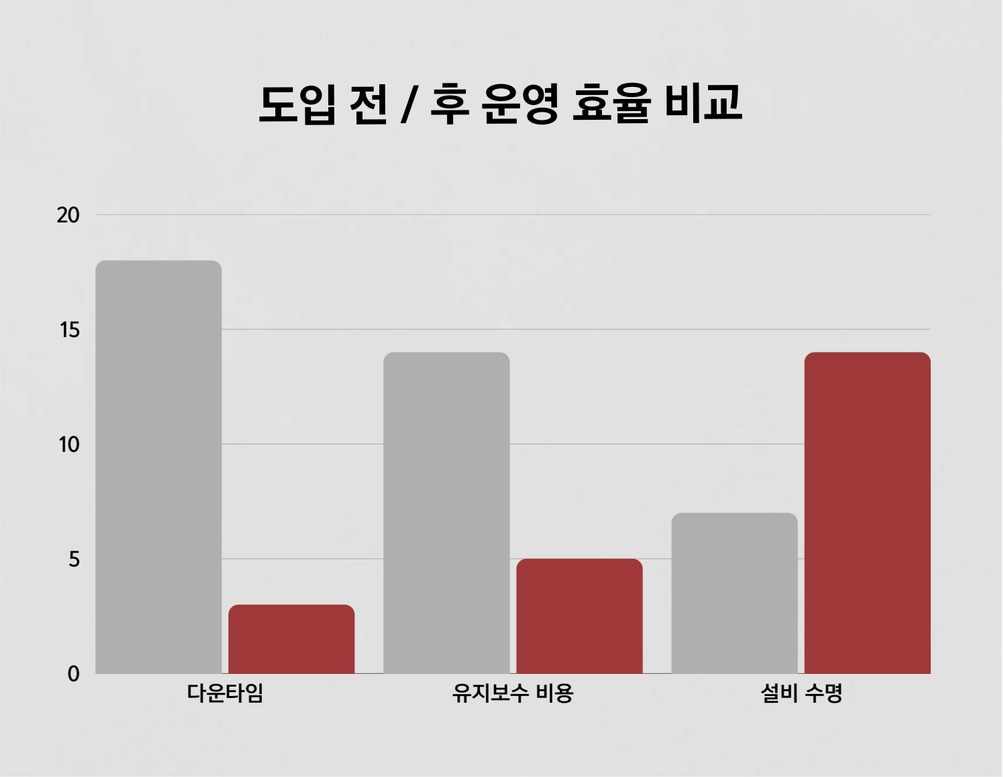

✔ 유지보수 비용 절감 및 다운타임 최소화

예고 없는 돌발 고장으로 인한 공정 중단(Downtime)을 사전에 차단하여 막대한 생산 손실을 방지합니다. 또한 불필요한 예방 정비 대신 데이터 기반의 적기 교체를 통해 전체 유지보수 비용을 획기적으로 낮춥니다.

✔ 설비 수명 연장 및 안전 확보

미세한 진동 불안정성(STD)과 기계적 충격을 조기에 감지하여 결함이 모터 전체로 번지는 것을 막습니다. 이를 통해 설비 본연의 수명을 극대화하고 기계 파손으로 인해 발생할 수 있는 2차 현장 안전사고를 원천 예방합니다.

✔ 데이터 기반의 신속한 의사결정 지원

초당 2,000건씩 쏟아지는 복잡한 센서 데이터를 직관적인 대시보드와 실시간 그래프로 시각화합니다. 이를 통해 관리자는 복잡한 데이터 분석 과정 없이도 시스템이 제공하는 즉각적인 경고 알림을 바탕으로 빠르고 정확한 유지보수 조치를 취할 수 있습니다.

시연

Q & A

1조 발표를 마칩니다.
감사합니다.

정동균(팀장), 이민아(부팀장), 김하린, 윤준서, 이용현, 황수민

1조 | 26.03.30. | 최종 발표